Gavrilă Paul-Alexandru
341C4

Proiect – Etapa 1

-raport-

În prima etapă a acestui proiect, am analizat caracteristicile unui set de date care conține imagini de computer tomograf (CT) cu scopul de a detecta diferite tipuri de hemoragii cerebrale. Am experimentat cu diferite transformări și operații de augmentare a imaginilor, urmând să implementez și să antrenez o rețea neuronală convoluțională (CNN) pe datele respective și să analizez predicțiile generate de modelul rezultat.

Pentru procesul de antrenare a rețelei neuronale, am lucrat într-un Jupyter Notebook pe Kaggle și am utilizat unul dintre acceleratorii disponibili pentru procesarea imaginilor (GPU NVIDIA T4 x2).

- ## Cerința 1 – Setul de Date

Pentru lucrul cu setul de date, am implementat clasa **RSNADataset**. Constructorul *__init__* preia calea spre directorul cu imaginile, setul de transformări dorit să fie aplicat imaginilor și citește datele din fișierul CSV cu etichetele pentru setul de date respectiv. Pentru că lucrăm cu variabile multiple per fotografie (5 pt. tipurile de hemoragie + 1 pt. sănătos/bolnav), datele vor fi memorare sub formă de dicționar unde cheia este numele imaginii iar elementele sunt liste care conțin cele 6 etichete. Metoda *__len__* returnează numărul de elemente (imagini CT) din setul de date. Metoda *__getitem__* asigură încărcarea lazy a imaginilor prin faptul că fișierele sunt citite de pe disc doar în momentul în care sunt cerute explicit de către DataLoader și aplică transformările specificate asupra imaginilor.

- ## Cerința 2 – Împărțirea Setului de Antrenare

Am proiectat funcția **get_train_val_split** pentru a obține un subset de date de validare din setul de date de antrenament. Parametrul *val_size*=0.2 respectă indicațiile din cerință (80% date de antrenament, 20% date de validare), dar poate fi modificat în funcție de nevoi. De asemenea, valoarea parametrului *random_state* poate fi modificată pentru a obține împărțiri diferite, ceea ce permite implementarea facilă a unei strategii de K-Fold Cross Validation pentru găsirea parametrilor optimi de antrenare în etapele viitoare.

Pentru a menține echilibrul între numărul de pacienți bolnavi și sănătoși din cele 2 subseturi, am folosit valorile atributului *any* pentru atributul *stratify* al funcției *train_test_split*, ceea ce asigură o distribuție similară a valorilor atributului respectiv în cele 2 subseturi.

Gavrilă Paul-Alexandru
341C4

- # Cerința 3 – Vizualizarea Distribuției Claselor

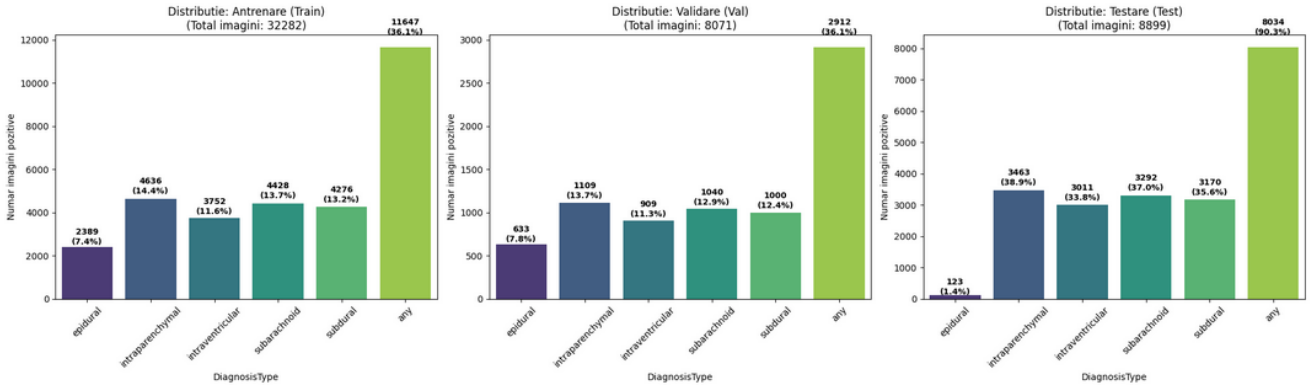

Am analizat distribuția tipurilor de hemoragii și a pacienților bolnavi din cele 3 seturi de date (antrenare, validare, testare) pornind de la următorul grafic:

Din reprezentarea grafică a distribuției claselor reies următoarele observații:

- setul de date de testare conține aproximativ un sfert din numărul de imagini din setul de date de antrenare
- distribuția tipurilor de hemoragii din seturile de date de antrenare și de validare este foarte similară, fapt datorat stratificării impuse în timpul împărțirii
- setul de date de testare conține un procentaj mult mai ridicat de exemple de pacienți bolnavi (aprox. 90%) comparativ cu celelalte seturi de date (aprox. 36%) - setul de date de testare este intenționat pentru a verifica drastic capacitatea modelului de a depista boala, nu este dată o importanță așa mare riscului de predicții fals-pozitive față de riscul de predicții fals-negative care ar duce la nedepistarea unor condiții medicale urgente și grave
- procentajul de hemoragii epidurale din setul de date de testare este mult mai redus față de celelalte 2 seturi de date

Pentru a rezolva problema discrepanței între numărul de pacienți bolnavi din seturile de date de antrenare și validare și cel de testare voi considera, la antrenare, exemplele de imagini care conțin hemoragii cu o greutate dublă față de cele fără hemoragii. Astfel, modelul va oferi atenție sporită identificării hemoragiilor și vom evita subantrenarea și posibilitatea de a nu identifica pacienți bolnavi la nevoie.

- # Cerința 4 – Analiza Vizuală a Tipurilor de Hemoragii

Am selectat aleator din setul de date de antrenare câte 7 imagini pentru fiecare tip de hemoragie reprezentat. Primul set de imagini conține exemple de pacienți sănătoși, pentru comparație. Deși pacienții pot avea simultan 2 sau mai multe tipuri de hemoragii, am ales să reprezint doar exemplele care ilustrează câte o singură categorie de hemoragie, pentru motive de claritate

Gavrilă Paul-Alexandru
341C4

Vizualizare: Sănătoși vs. Patologii Exclusive (din primele 1000)

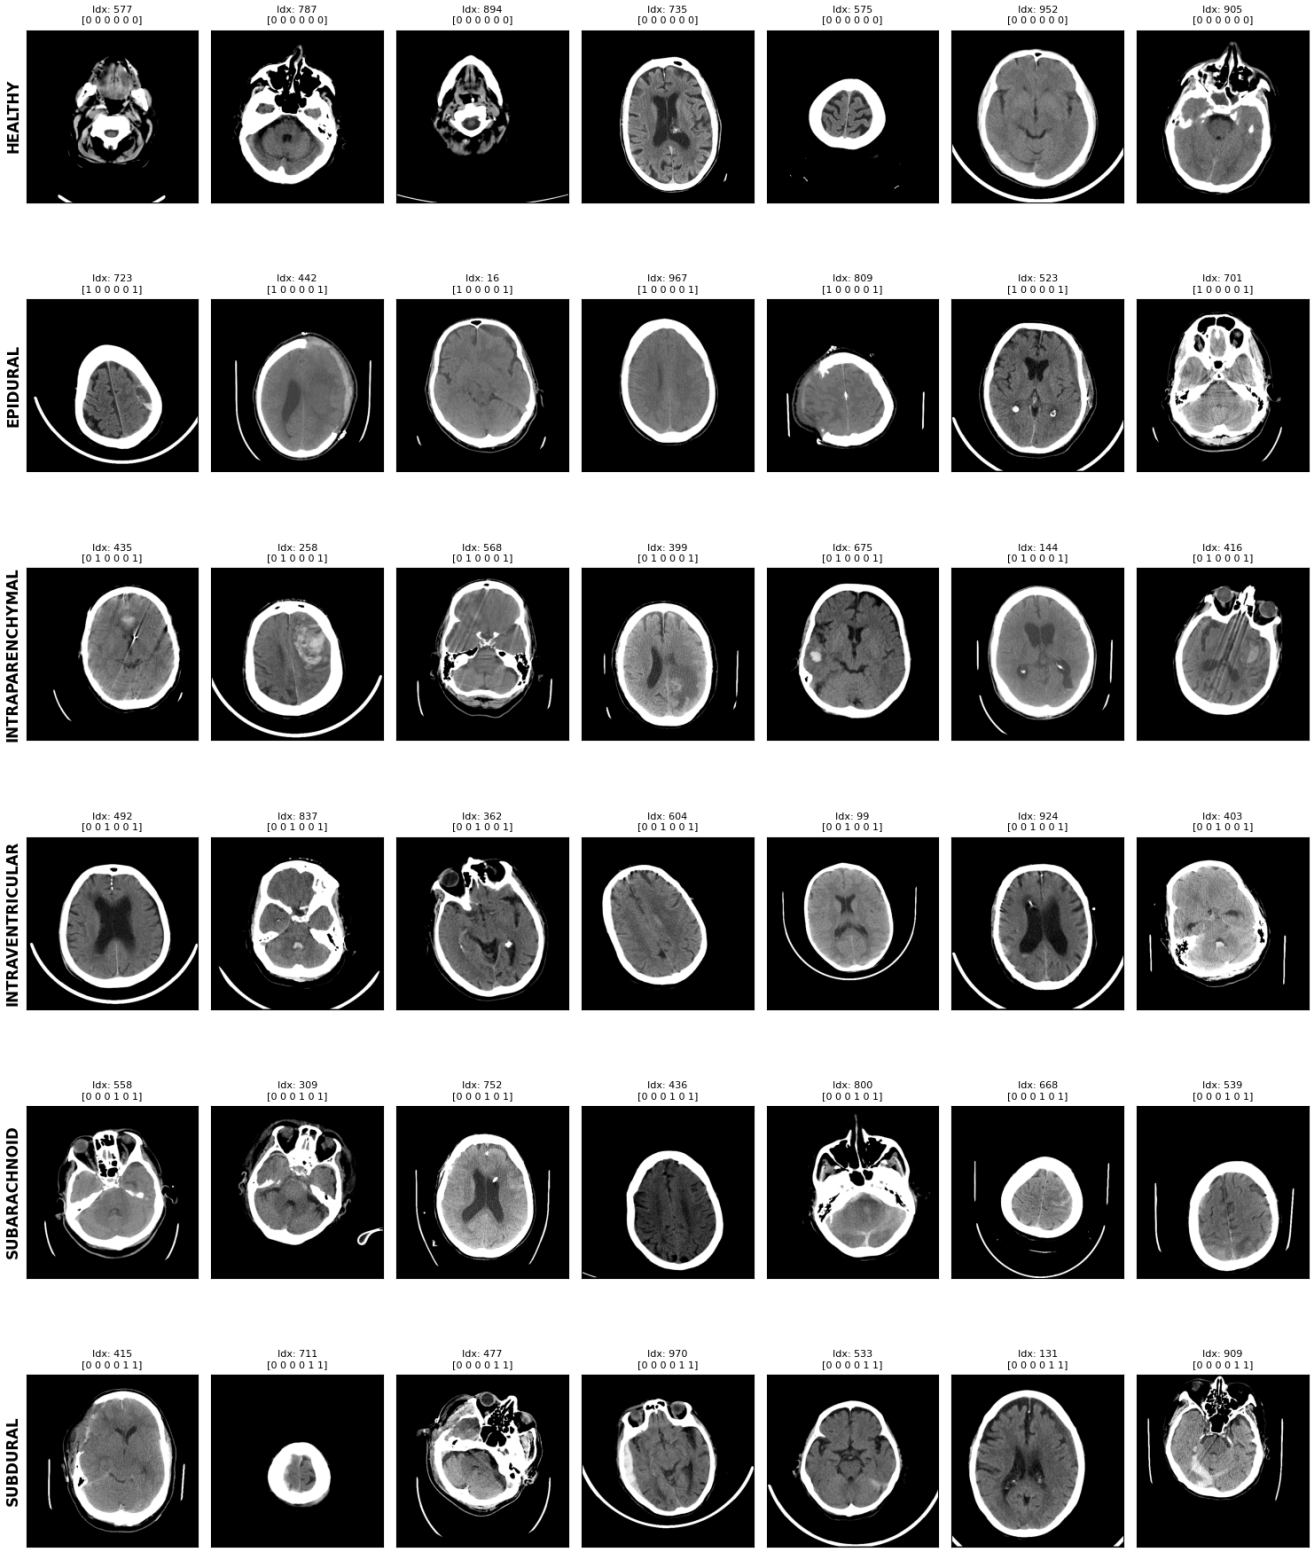

Gavrilă Paul-Alexandru
341C4

Hemoragia **epidurală** apare ca o zonă gri deschis în formă de lentilă biconvexă. Este localizată la periferia creierului, între craniu și dura mater (membrana care acoperă encefalul). Fiindcă sângele este ținut pe loc de membrana atașată strâns de craniu, se observă cum creierul este împins în interior din cauza presiunii locale.

Hemoragia **intraparenchimală** se manifestă sub formă de pete albicioase neregulate în mijlocul creierului (în interiorul țesutului cerebral, în materia albă sau cenușie a creierului). Petele reprezintă zone de sânge închegat și, în unele cazuri, sunt înconjurate de o zonă puțin mai întunecată.

Hemoragia **intraventriculară** este similară cu cea intraparenchimală, fiind cele 2 tipuri de hemoragii în interiorul parenchimului, membrana din centrul creierului. Apar tot sub formă de pete albe în centrul encefalului, dar diferă prin faptul că umplu cavitățile centrale ale creierului, care apar de obicei ca fiind negre (pline cu lichid) în loc să apară neregulat în materia albă și cenușie. Se observă cel mai clar în imaginile CT care evidențiază ventriculii laterali.

Hemoragia **subarahnoidiană** apare sub formă de linii albe neregulate care urmăresc contururile interioare ale encefalului, datorate faptului că sângele inundă șanțurile creierului. Poate arăta similar cu celelalte tipuri de hemoragii fiindcă se poate manifesta în aproape orice regiune a creierului, inclusiv în zonele în care se regăsesc de obicei alte tipuri de hemoragii localizate (intraventriculare în ventriculii laterali, subdurale la periferia creierului, etc.).

Hemoragia **subdurală** este similară cu cea epidurală, diferența fiind că se manifestă de cealaltă parte a membranei care înconjoară encefalul, ajungând până la membrana arahnoidă. Are forma unei semiluni, fiind convexă pe partea dinspre craniu și concavă pe partea dinspre creier. Comparativ cu hemoragia epidurală, poate apărea mai îngustă, dar mai lungă, desfășurată de-a lungul conturului periferiei creierului. În cazurile în care sângerarea este redusă, este greu de diferențiat forme de semilună față de cea de lentilă biconvexă, îngreunând clasificarea între cele 2 categorii.

Unele hemoragii sunt mari și ușor de observat în timp ce altele apar sub formă de câteva puncte albe dificil de diferențiat de țesutul normal, fapt ce va necesita o antrenare mai riguroasă a modelului pentru anumite cazuri. De asemenea, există detalii estetice care pot încurca predicțiile modelului, cum ar fi faptul că sângele, cu timpul, tinde de la alb spre o nuanță de gri sau faptul că masa osoasă a craniului poate masca hemoragiile periferice din cauză că ambele sunt detectate ca fiind de un alb strălucitor.

Gavrilă Paul-Alexandru
341C4

- **Cerința 5 – Analiza Integrității și Consistenței Setului de Date**

  - a) Verificarea numărului de canale al imaginilor

În urma verificărilor, am constatat că toate imaginile din setul de date au 1 canal (format grayscale/luminanță), acesta fiind și formatul nativ al imaginilor de Computer Tomograf.

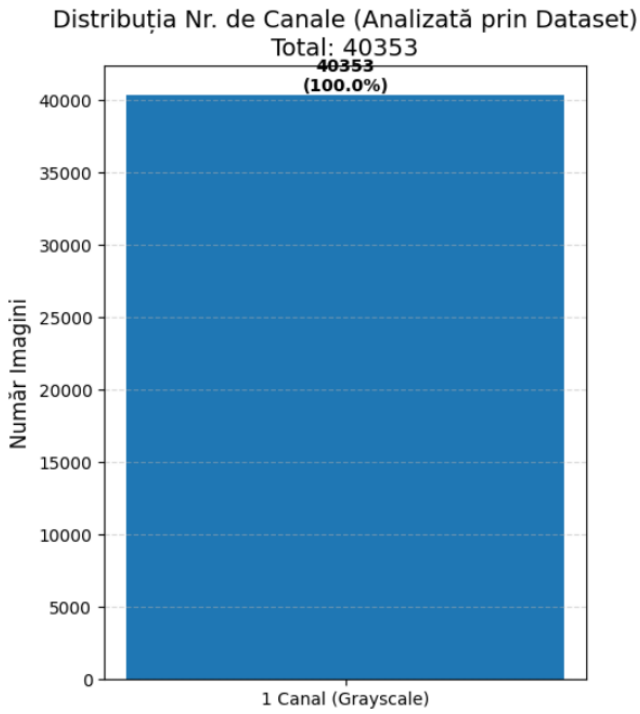

Figure 2: Setul de antrenament/validare

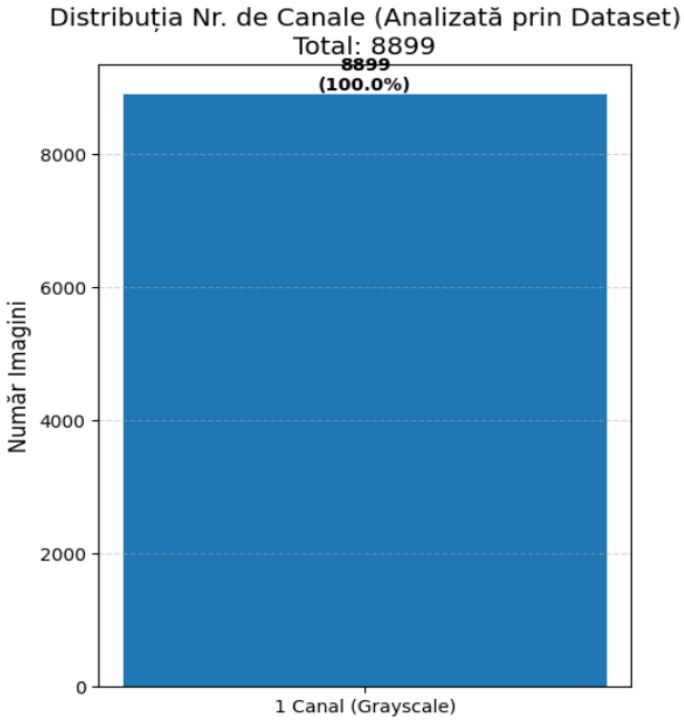

Figure 1: Setul de testare

  - b) Verificarea dimensiunilor imaginilor

Majoritatea covârșitoare a imaginilor din ambele seturi de date au dimensiunea **512x512**, existând câteva exemplare cu dimensiuni diferite. Pentru a uniformiza dimensiunile imaginilor CT și pentru a nu aglomera inutil resursele de calcul în timpul antrenării modelului, am decis să reduc toate imaginile din setul de date la dimensiunea **256x256**, suficient de mare pentru a capta detaliile subtile dar și suficient de mică pentru a asigura antrenarea modelului într-un interval de timp acceptabil.

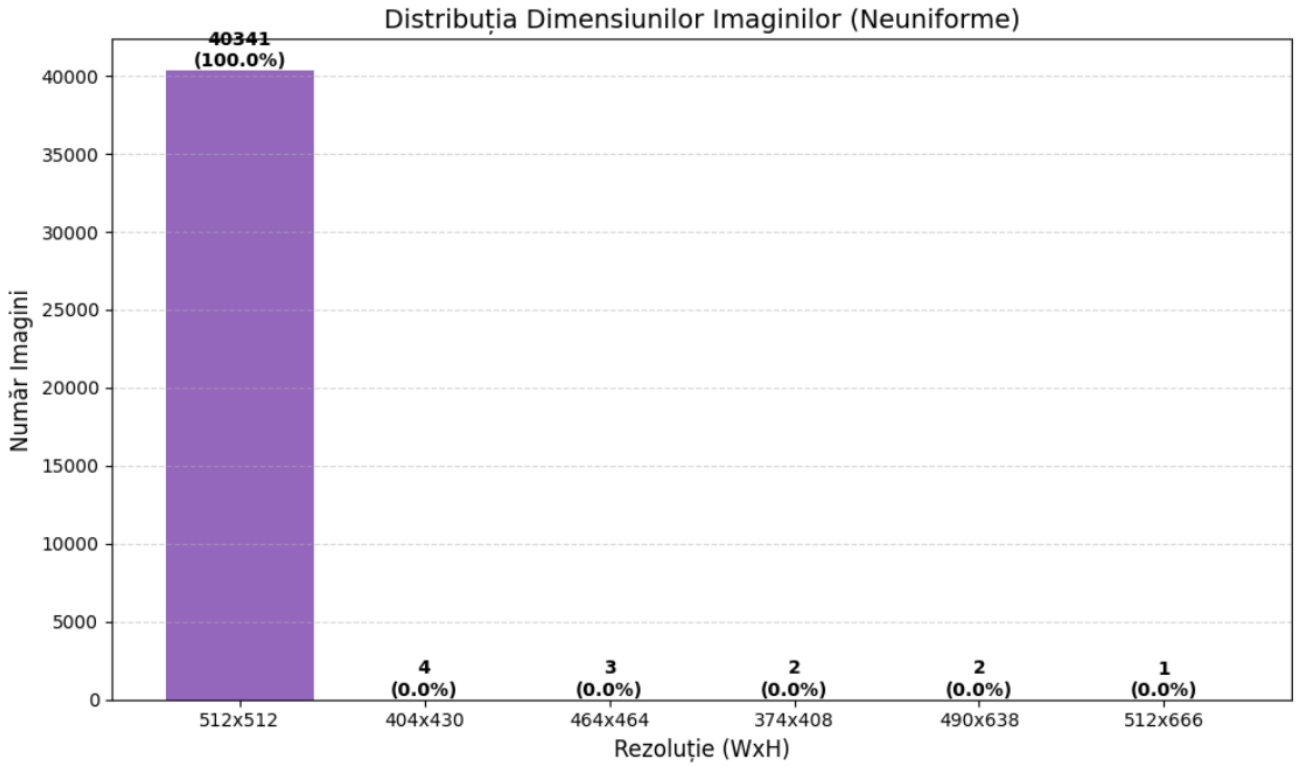

Figure 3: Setul de antrenament/validare

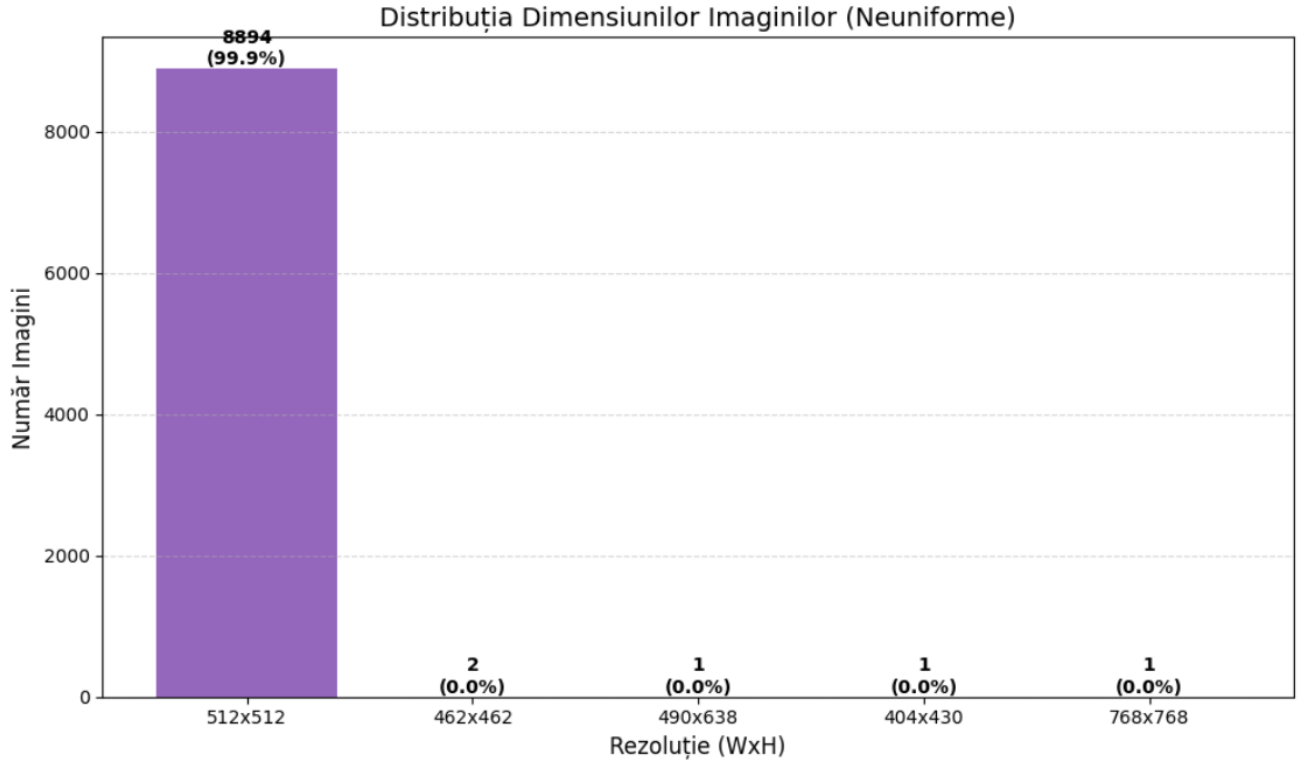

Figure 4: Setul de testare

- ## c) Scalarea valorilor pixelilor din imaginile de CT

În momentul actual, valorile pixelilor din imaginile din cele 2 seturi de date se află în intervalul **[0, 255].** Acest lucru este normal fiindcă am memorat imaginile în format PIL (*Image.open()*). Imaginile originale de CT erau reprezentate utilizând valori Hounsfield (între -1000 și 3000), însă acestea au fost pierdute prin conversia la formatul .png. Pentru antrenare vom rescala valorile pixelilor în intervalul **[0, 1]** prin conversia imaginilor în ***torch.tensor*** după aplicarea transformărilor, modelului fiindu-i mult mai ușor să lucreze pe un interval cu valori reduse.

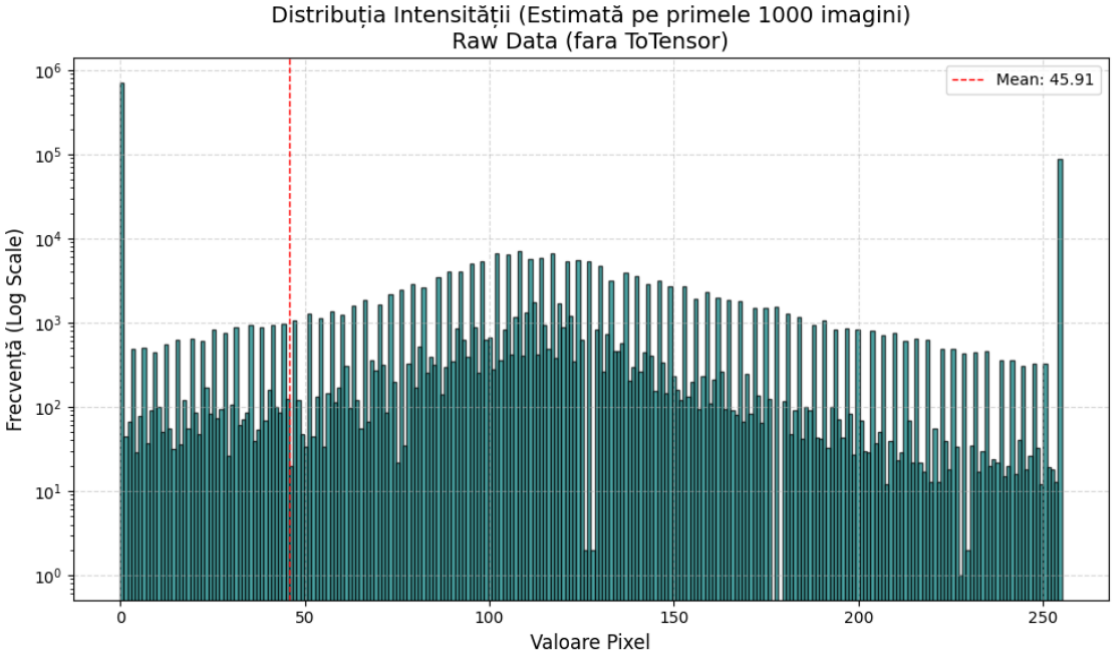

Figure 5: Setul de antrenament/validare

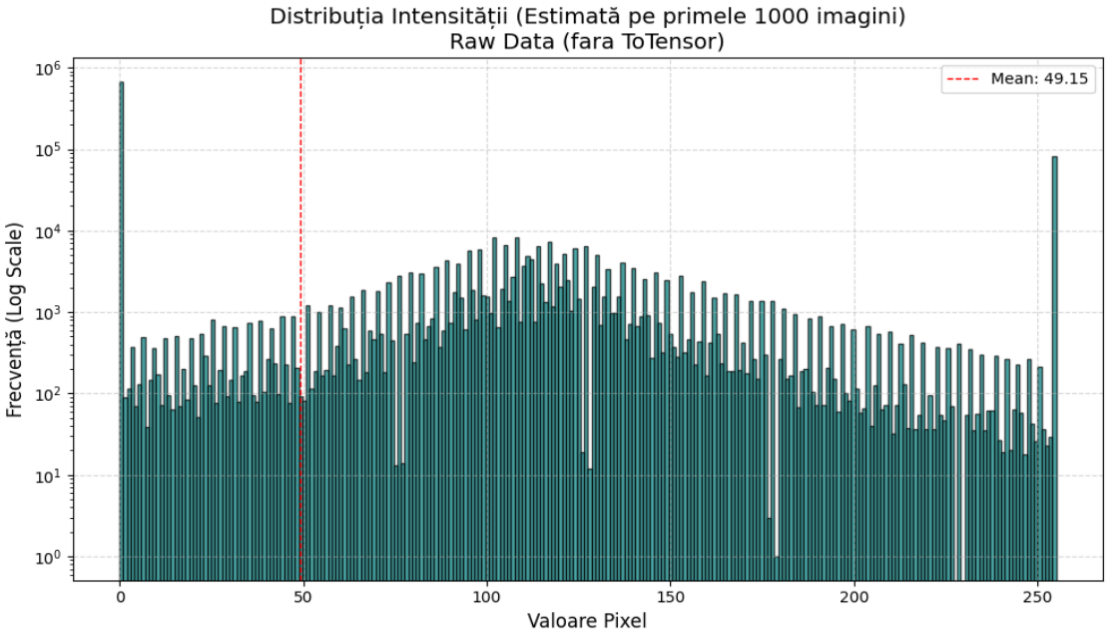

Figure 6: Setul de testare

Gavrilă Paul-Alexandru
341C4

- # Cerința 6 – Operații de Preprocesare și Normalizare

Pipeline-ul de preprocesare pentru cele 3 seturi de date conține următoarele transformări:

- **redimensionarea** imaginilor la 256 x 256
- aplicarea **filtrului CLAHE** asupra imaginilor
- conversia imaginilor în **torch.tensor**
- normalizarea valorilor pixelilor în jurul mediei cu deviația standard

Filtrul **CLAHE (Contrast Limited Adaptive Histogram Equalization** aplică operații de îmbunătățire vizuală asupra imaginilor de Computer Tomograf. Hemoragiile pot avea o nuanță de gri foarte asemănătoare cu cea a țesutului sănătos sau o nuanță de alb ce poate fi confundată cu cea a craniului în cazul sângerărilor din zona periferică. Filtrul crește contrastul local, evidențiind zona afectată de hemoragie și crescând rata de recunoaștere a modelului de învățare automată.

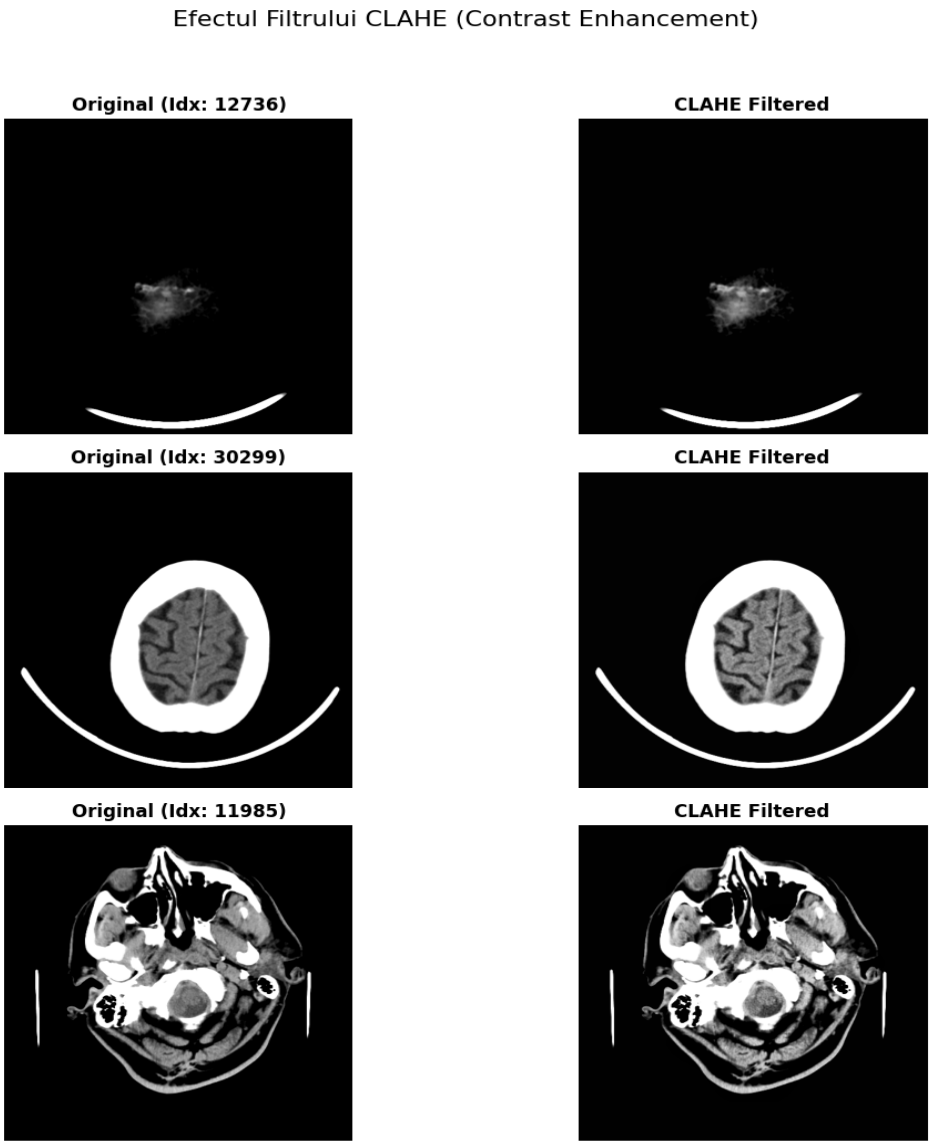

Gavrilă Paul-Alexandru
341C4

În realitate, imaginile folosite în predicții pot fi alterate (tăiate, rotite, întoarse, etc. în moduri care nu apar în datele de antrenament), dar ar fi ideal ca modelul să poată să ofere predicții exacte chiar și când calitatea datelor lasă de dorit. Pentru a antrena modelul în așa fel încât să fie eficient în astfel de situații, asupra setului de date de antrenament am aplicat o serie de transformări aleatorii (*crop aleatoriu, rotire orizontală aleatorie* și *rotire verticală aleatorie*) care să simuleze posibilele variații care pot apărea în utilizarea zilnică într-o instituție medicală.

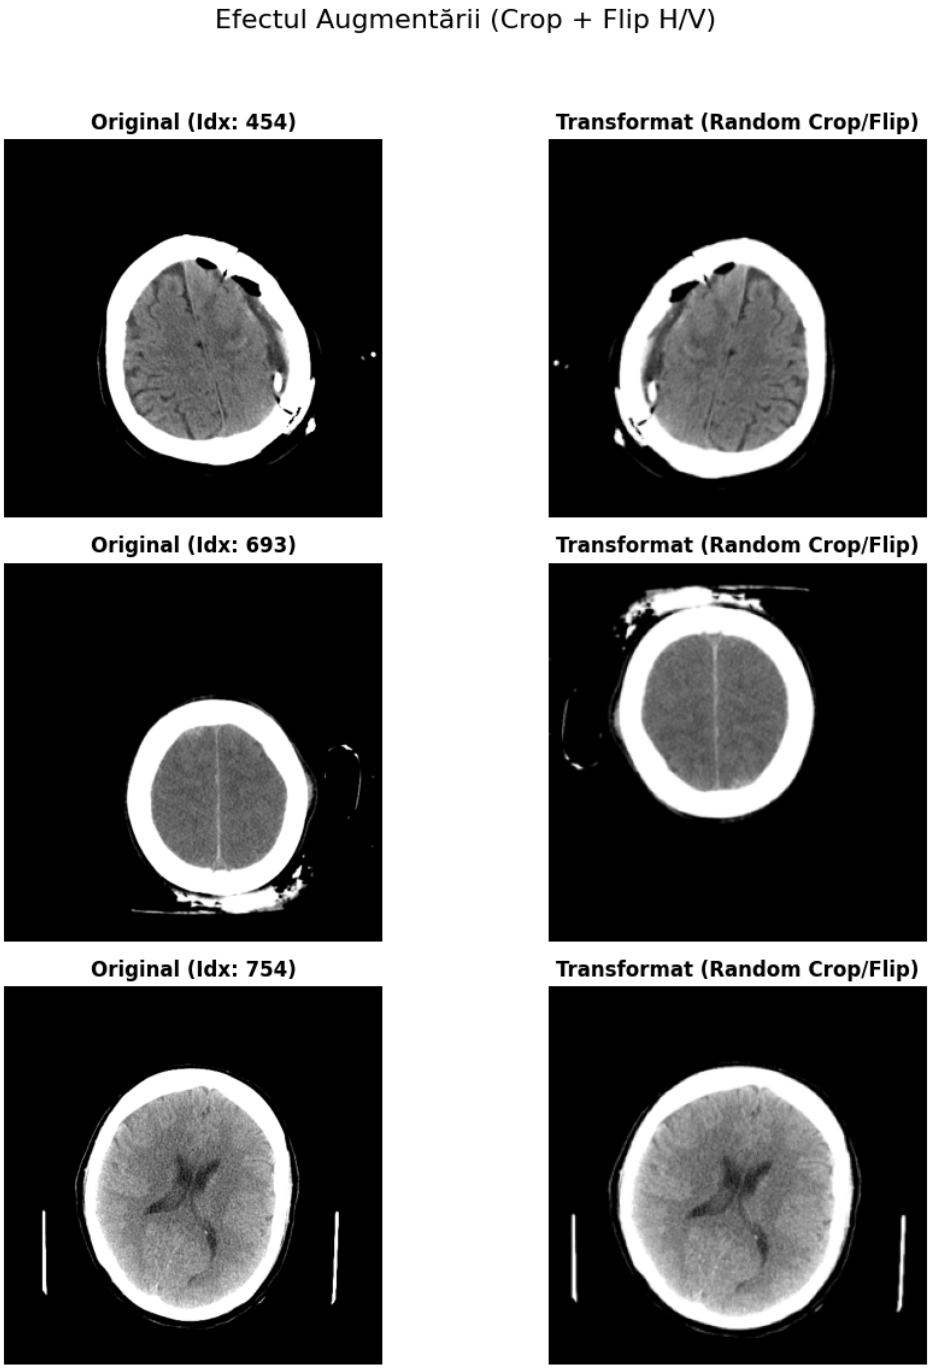

Gavrilă Paul-Alexandru
341C4

- # Cerința 7 – Antrenarea și Testarea Rețelei Neurale

  - ## 1) Încărcarea Datelor

Pentru a asigura încărcarea lazy a datelor (imaginile sunt stocate în memorie doar la momentul în care sunt procesate) am utilizat clasa pe care am proiectat-o pentru prima cerință. Am inițializat seturile de date de antrenament și de testare și am efectuat împărțirea antrenare-validare pentru a obține și setul de date de validare. Pentru setul de date de validare am utilizat setul de transformări pentru setul de date de testare, fiindcă aplicarea de rotiri și decupări aleatorii este necesară doar în timpul antrenării. În timpul proceselor de antrenare și de testare, datele vor fi procesate cu ajutorul clasei DataLoader, care încarcă în memoria modelului strict imaginile care sunt folosite în momentul respectiv pentru a nu aglomera inutil resursele computaționale disponibile.

  - ## 2) Definirea Modelului

Rețeaua neuronală utilizată pentru antrenarea modelului a fost implementată în interiorul clasei **HemorrhageCNN**, fiind o rețea neuronală convoluțională ce moștenește clasa *nn.Module.* Aceasta servește drept model de bază (baseline), având o structură ierarhică menită să recunoască trăsături vizuale în imaginile încărcate. Rețeaua este compusă dintr-un extractor de trăsături, format din 4 straturi convoluționale succesive, urmat de un clasificator.

Deoarece un pacient poate prezenta simultan mai multe tipuri de hemoragii, avem de a face cu o problemă de **Multi-Label Classification**. Spre deosebire de o clasificare clasică unde aș fi folosit la final *softmax* sau *sigmoid* ca funcții de activare, în cazul acesta nu aplic nicio funcție de activare și returnez valorile brute (*logits*) rezultate pe parcursul procesului de antrenare. Această abordare este necesară pentru a utiliza funcția **BCEWithLogitsLoss** ca funcție de pierdere în etapa de antrenare.

  - ## 3) Definirea Funcției de Pierdere și a Optimizatorului

La fel cum am descris mai sus, am utilizat funcția de pierdere **BCEWithLogitsLoss** pentru a putea interpreta rezultatul problemei de multi-label classification într-un mod corect și eficient. Această funcție integrează stratul Sigmoid în mod optimizat, permițând tratarea fiecărei clase ca o problemă de clasificare binară independentă. Conform explicațiilor de la Cerința 3, am dat ca argument pentru parametrul *pos_weight* greutăți de 2.0 pentru fiecare etichetă din setul de date, fapt ce obligă modelul să penalizeze dublu rezultatele fals negative față de cele fals pozitive, fapt ce ar diminua impactul numărului dezechilibrat de pacienți bolnavi din setul de date de antrenament.

Am ales să folosesc **optimizatorul Adam** fiindcă ajustează automat rata de învățare pentru fiecare parametru în parte, gestionând eficient imaginile CT care conțin mulți pixeli negri de fundal care trebuie ignorați în favoarea zonelor relevante. Am setat rata de învățare la valoarea 0.0001 pentru a asigura stabilitate modelului și pentru a spori detecția detaliilor fine și parametrul *weight_decay* la valoarea 1e-6 ca termen de regularizare pentru a preveni overfitting-ul în timpul antrenării.

4) Antrenarea Modelului

Pentru antrenarea rețelei neurale am utilizat clasa **Trainer** pentru a gestiona ciclul complet de învățare, adaptată specific pentru *clasificarea multi-label* prin faptul că se aplică sigmoid asupra celor 6 ieșiri ale modelului urmate de un prag de binarizare de 0.5. Progresul procesului de antrenare este actualizat frecvent, afișându-se informații la finalul fiecărei epoci de antrenare și la fiecare 20 de pași ai epocii. Se salvează automat pe disc starea modelului (best_model.pth) în momentul în care eroarea pe setul de validare scade, garantându-se reținerea versiunii cu cel mai bun grad de generalizare. De asemenea, se rețin metricile din timpul antrenării necesare pentru analiza ulterioară a rezultatelor. Am ales să rulez 25 de epoci de antrenare, fiind un număr echilibrat care permite antrenarea robustă a modelului într-un timp bun de execuție.

5) Evaluarea Modelului

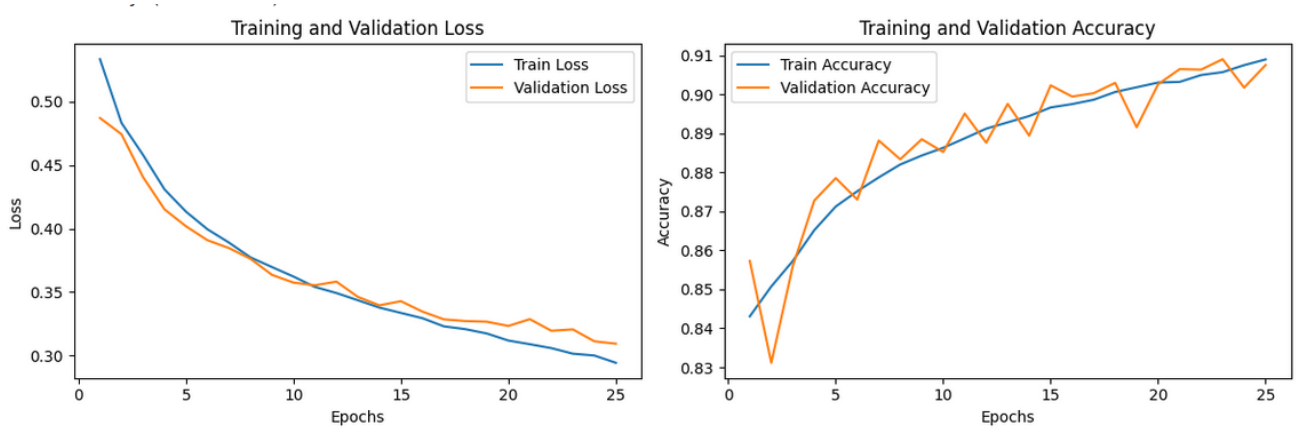

Figure 7: Statistici după antrenare și validare

Modelul a obținut o acuratețe exactă (toate label-urile prezise) de **30.19%** și o acuratețe per-etichetă de **81.53%.**

Table 1: Statistici detaliate pe clase

CLASĂ	PRECISION	RECALL	F1-SCORE	SUPPORT
Epidural	0.10	0.52	0.17	123
Intraparenchymal	0.75	0.73	0.74	3463
Intraventricular	0.73	0.82	0.77	3011
Subarachnoid	0.58	0.61	0.59	3292
Subdural	0.69	0.54	0.61	3170
Any	0.99	0.88	0.93	8034
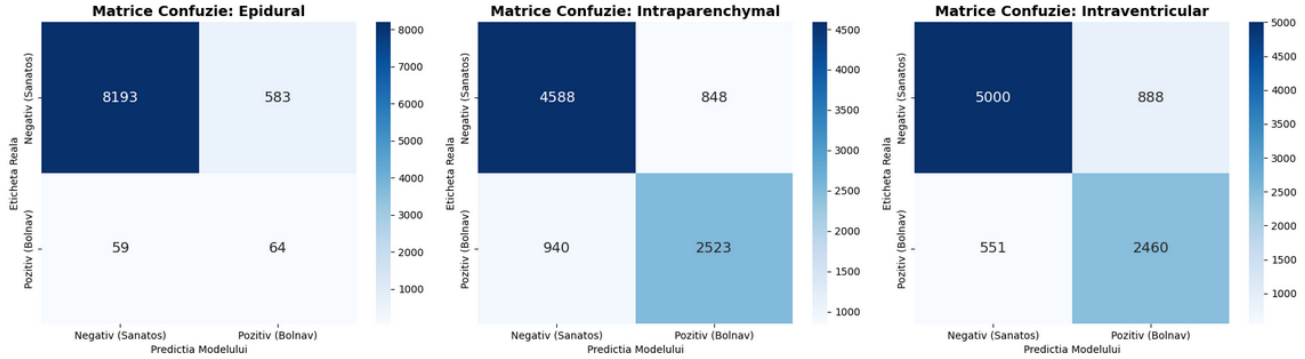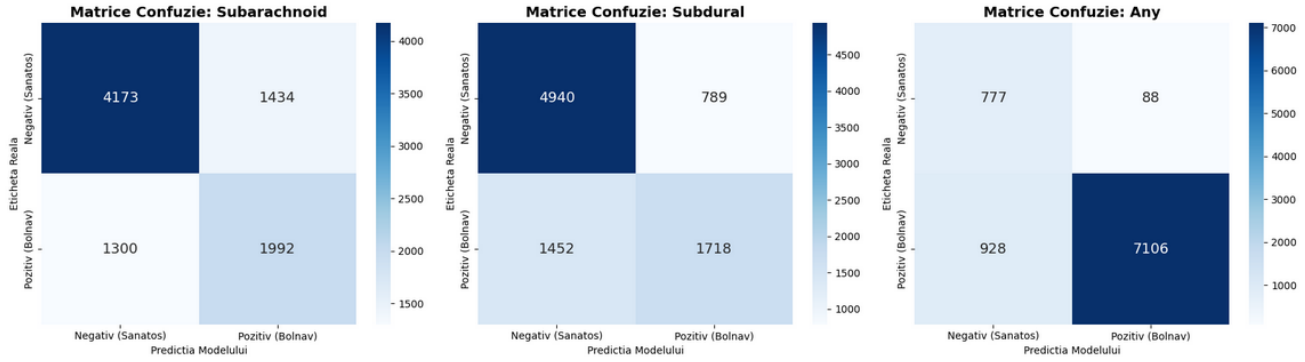
Gavrilă Paul-Alexandru
341C4